


MIMO Detection

O MIMO:



$$s_{r_0} = c_0 h_{00} + c_1 h_{01} + n_0$$

$$s_{r_1} = c_0 h_{10} + c_1 h_{11} + n_1$$

$$\begin{bmatrix} s_{r_0} \\ s_{r_1} \end{bmatrix} = \begin{bmatrix} h_{00} & h_{01} \\ h_{10} & h_{11} \end{bmatrix} \times \begin{bmatrix} c_0 \\ c_1 \end{bmatrix} + \begin{bmatrix} n_0 \\ n_1 \end{bmatrix}$$

$$\vec{s_r} = \mathbf{H} \vec{c} + \vec{n}$$

Reparametrizações e convenções utilizadas:

- Vetores apresentando os valores das partes real e imaginária dos símbolos

$$\mathbf{y} = \mathbf{H}\mathbf{x} + \mathbf{w}$$

$$\mathbf{y} = \begin{bmatrix} \Re(\bar{\mathbf{y}}) \\ \Im(\bar{\mathbf{y}}) \end{bmatrix} \mathbf{H} = \begin{bmatrix} \Re(\bar{\mathbf{H}}) & -\Im(\bar{\mathbf{H}}) \\ \Im(\bar{\mathbf{H}}) & \Re(\bar{\mathbf{H}}) \end{bmatrix} \mathbf{x} = \begin{bmatrix} \Re(\bar{\mathbf{x}}) \\ \Im(\bar{\mathbf{x}}) \end{bmatrix} \quad \mathbf{w} = \begin{bmatrix} \Re(\bar{\mathbf{w}}) \\ \Im(\bar{\mathbf{w}}) \end{bmatrix}$$

- One-hot mapping

Para a modulação QPSK

$$s_1 = -3 \leftrightarrow \mathbf{u}_1 = [1, 0, 0, 0]$$

$$s_2 = -1 \leftrightarrow \mathbf{u}_2 = [0, 1, 0, 0]$$

$$s_3 = 1 \leftrightarrow \mathbf{u}_3 = [0, 0, 1, 0]$$

$$s_4 = 3 \leftrightarrow \mathbf{u}_4 = [0, 0, 0, 1]$$

Generalizando:

$$s_i = f_{oh}(\mathbf{u}_i) \text{ for } i = 1, \dots, |\mathbb{S}|$$

$$x = f_{oh}(\mathbf{x}_{oh}) = \sum_{i=1}^{|\mathbb{S}|} s_i [\mathbf{x}_{oh}]_i$$

Há uma arquitetura:

$$\hat{\mathbf{x}}_{oh}(\mathbf{H}, \mathbf{y}; \boldsymbol{\theta})$$

Há uma função de perda:

$$l(\mathbf{x}_{oh}; \hat{\mathbf{x}}_{oh}(\mathbf{H}, \mathbf{y}; \boldsymbol{\theta}))$$

O objetivo do treinamento é:

$$\min_{\boldsymbol{\theta}} E \{l(\mathbf{x}_{oh}; \hat{\mathbf{x}}_{oh}(\mathbf{H}, \mathbf{y}; \boldsymbol{\theta}))\}$$

Encontrar os parâmetros ótimos, de modo que a função de perda apresente o menor valor possível.

Premissa:

- Parte-se do pressuposto de que há perfeito conhecimento de CSI (channel state information).

Casos apresentados:

- Fixed Channel (FC) – H apresenta comportamento determinístico;
- Varying Channel (VC) – H apresenta comportamento aleatório.

O sinal recebido é dado por:

$$\mathbf{H}^T \mathbf{y} = \mathbf{H}^T \mathbf{H} \mathbf{x} + \mathbf{H}^T \mathbf{w}$$

As iterações são dadas por:

$$\hat{\mathbf{x}}_{k+1} = \Pi \left[\hat{\mathbf{x}}_k - \delta_k \mathbf{H}^T \mathbf{y} + \delta_k \mathbf{H}^T \mathbf{H} \mathbf{x}_k \right]$$

São aplicadas não-linearidades padrão, a fim de enriquecer as iterações do modelo:

$$\mathbf{q}_k = \hat{\mathbf{x}}_{k-1} - \delta_{1k} \mathbf{H}^T \mathbf{y} + \delta_{2k} \mathbf{H}^T \mathbf{H} \mathbf{x}_{k-1}$$

$$\mathbf{z}_k = \rho \left(\mathbf{W}_{1k} \begin{bmatrix} \mathbf{q}_k \\ \mathbf{v}_{k-1} \end{bmatrix} + \mathbf{b}_{1k} \right)$$

$$\hat{\mathbf{x}}_{oh,k} = \mathbf{W}_{2k} \mathbf{z}_k + \mathbf{b}_{2k}$$

$$\hat{\mathbf{x}}_k = \mathbf{f}_{oh}(\hat{\mathbf{x}}_{oh,k})$$

$$\hat{\mathbf{v}}_k = \mathbf{W}_{3k} \mathbf{z}_k + \mathbf{b}_{3k}$$

$$\hat{\mathbf{x}}_0 = \mathbf{0}$$

$$\hat{\mathbf{v}}_0 = \mathbf{0},$$

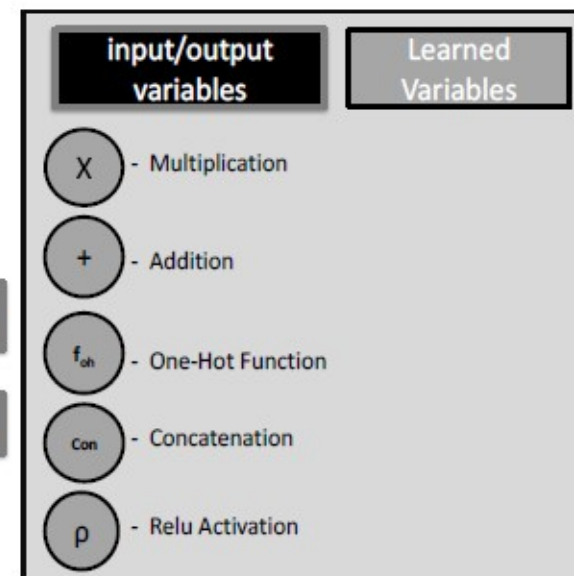
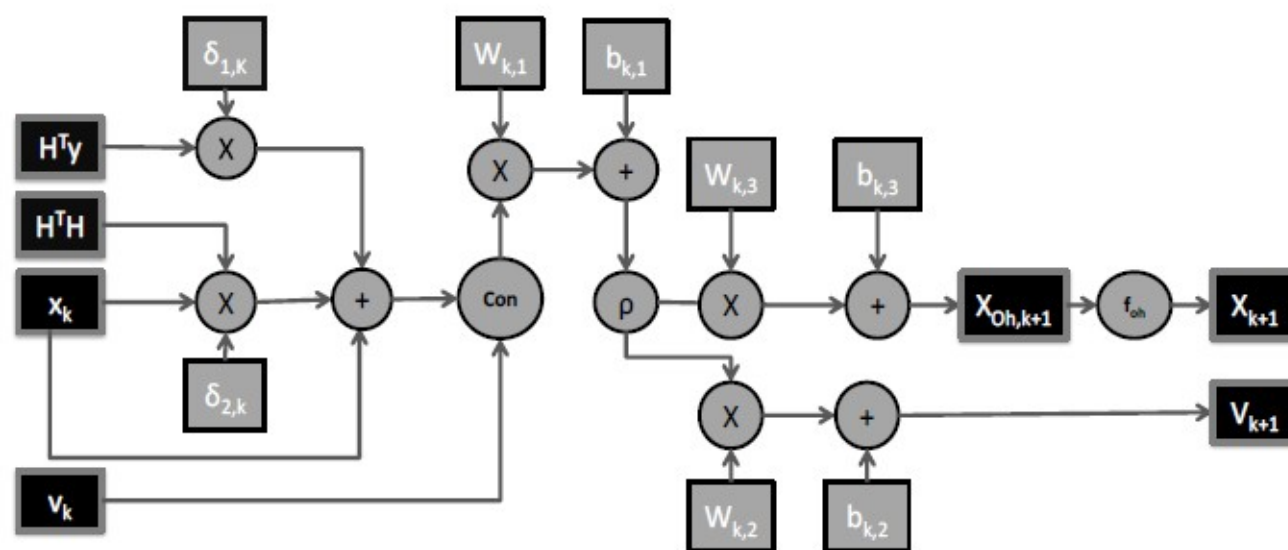
Parâmetros otimizados na fase de treinamento:

$$\theta = \{W_{1k}, b_{1k}, W_{2k}, b_{2k}, W_{3k}, b_{1k}, \delta_{1k}, \delta_{2k}\}_{k=1}^L$$

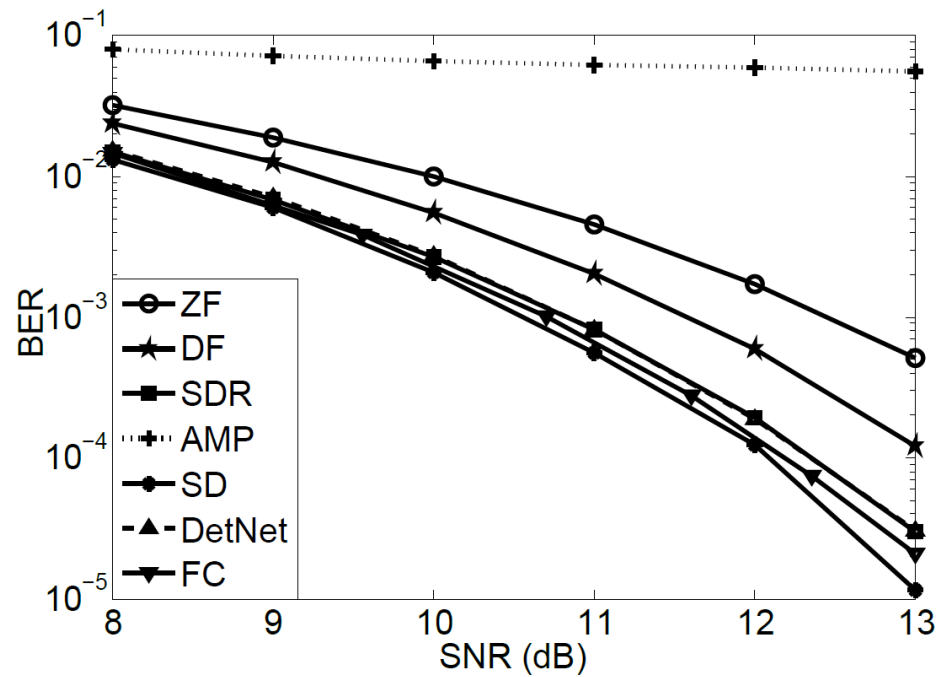
A função de perda assume a seguinte forma:

$$l(x_{oh}; \hat{x}_{oh}(\mathbf{H}, \mathbf{y}; \theta)) = \sum_{l=1}^L \log(l) \|\mathbf{x}_{oh} - \hat{\mathbf{x}}_{oh,l}\|^2$$

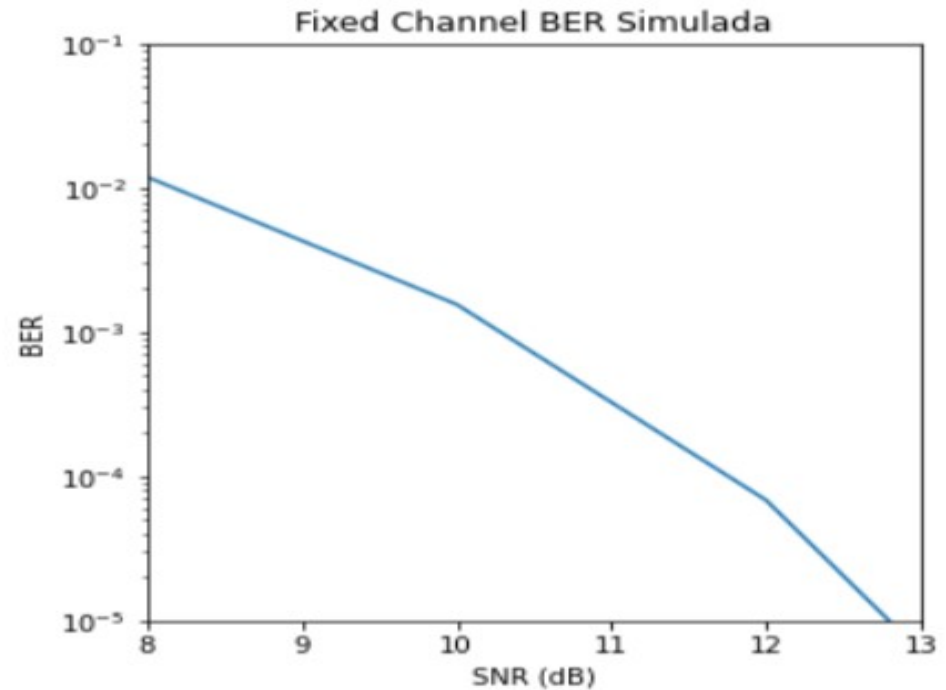
Estrutura do DetNet:




Resultados fixed channel (FC):



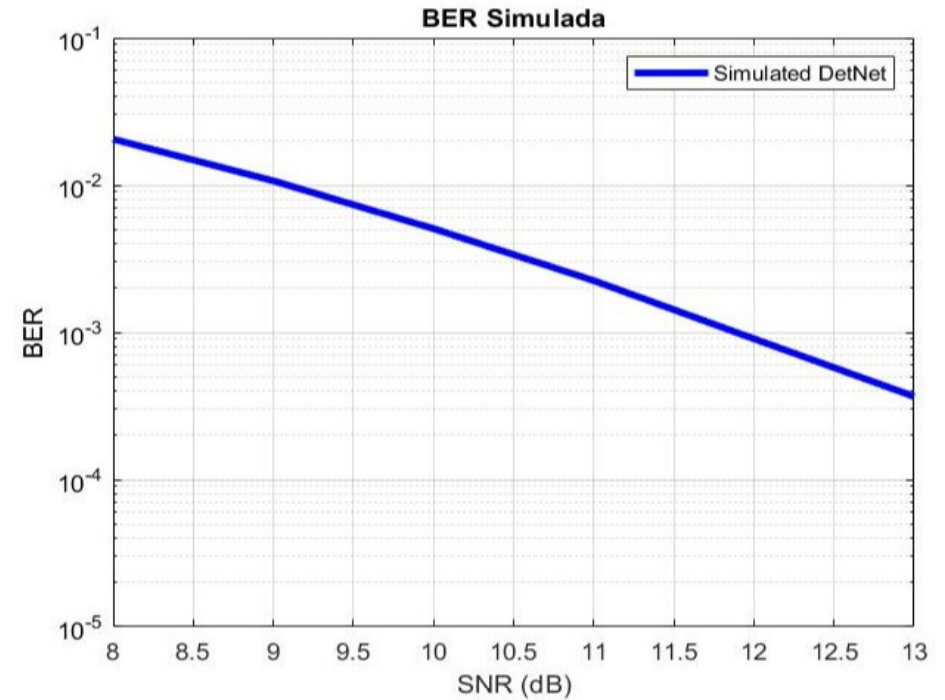
Resultado simulado:



Resultados varying channel (VC):



Resultado simulado:



- **Análise da precisão da DetNet para ordens de modulação mais elevadas**
Ex: SER e BER para modulações acima de 64QAM
- **Análise do tempo de execução para modulações mais elevadas**
Ex: encontrar relação de compromisso entre o número de camadas da rede neural (L), a precisão desejada e o tempo de execução necessário

Obrigado!

